

به نام خدا



تمرین سری یازدهم درس یادگیری عمیق

دکتر محمدی

محمد یارمقدم

۹۶۴۶۲۱۰۴

## سوال اول)

برای حل این سوال به ترتیب از اولین لایه آغاز و پیش می‌رویم.

- اولین لایه کانولوشن است. این لایه ۶۴ فیلتر با سایز ۷\*۷ دارد. تعداد پارامترهای این لایه طبق رابطه زیر بدست می‌آید:  
$$\# \text{ of parameters} = ((7*7*1) + 1) * 64 = 3200$$

زیرا همه فیلترها برای لایه‌ها یکسان هستند پس ۴۹ پارامتر برای هر فیلتر موجود است که با بایاس ۵۰ عدد می‌شود.  
خروجی نیز (24, 24, 1) می‌شود. زیرا باید ابعاد فیلتر را از ابعاد عکس ورودی کم کنیم. پس:  
$$\text{Output\_size} = \text{in\_size} - \text{filter\_size} = (30, 30) - ((7, 7) - (1, 1)) = (24, 24)$$

حال چون ۶۴ فیلتر داریم پس خروجی نهایی (24, 24, 60) می‌شود.
- لایه دوم maxpooling ۲ بعدی است. این لایه پارامتر قابل یادگیری ندارد. چون گام این لایه ۲\*۲ است پس سایز ورودی را نصف می‌کند. پس سایز خروجی (12, 12, 64) می‌شود.
- لایه سوم کانولوشن است. این لایه ۱۲۸ فیلتر با سایز ۵\*۵ دارد. به علاوه ۶۴ عمق دارد. پس ۶۴\*۲۵ پارامتر دارد. یک بایاس نیز دارد. پس:  
$$\# \text{ of parameters} = ((64*25) + 1) * 128 = 204928$$

مانند مورد قبل نیز سایز خروجی را به صورت زیر بدست می‌آوریم:  
$$\text{Output\_size} = \text{in\_size} - \text{filter\_size} = (12, 12) - ((5, 5) - (1, 1)) = (8, 8) \rightarrow \text{final} = (8, 8, 128)$$
- لایه چهارم نیز maxpooling ۲ بعدی است. مانند قبل داریم:  
$$\text{Output\_size} = (8/2, 8/2, 128) = (4, 4, 128)$$
- لایه پنجم کانولوشن است. این لایه ۲۵۶ فیلتر با سایز ۳\*۳ دارد. به علاوه ۱۲۸ عمق دارد. پس ۹\*۱۲۸ پارامتر دارد. یک بایاس نیز دارد. پس:  
$$\# \text{ of parameters} = ((128*9) + 1) * 256 = 295168$$

مانند مورد قبل نیز سایز خروجی را به صورت زیر بدست می‌آوریم:  
$$\text{Output\_size} = \text{in\_size} - \text{filter\_size} = (4, 4) - ((3, 3) - (1, 1)) = (2, 2) \rightarrow \text{final} = (2, 2, 256)$$
- لایه ششم نیز maxpooling ۲ بعدی است. مانند قبل داریم:  
$$\text{Output\_size} = (2/2, 2/2, 256) = (1, 1, 256)$$
- لایه هفتم flatten است. این لایه ورودی را تبدیل به یک بعد می‌کند پس خروجی (256) است و پارامتر ندارد.
- لایه هشتم Dense است. این لایه به تمام لایه قبل متصل است. پس:  
$$\# \text{ of parameters} = (256 + 1) * 128 = 32896$$

خروجی نیز تعداد unit است پس (128) می‌شود.
- لایه‌های نهم Embedding ها هستند.  
در هر لایه داریم که این لایه قابلیت پشتیبانی از ۱۰۰۰ کلمه منحصر به فرد را دارد و به ازای هر کلمه یک بردار ۲۵۶ تایی در نظر خواهد می‌گیرد. به علاوه ۲۵۶ ورودی و ۱۰۰۰ نورون لایه مخفی و ۲۵۶ خروجی دارد. پس:  
$$\# \text{ of parameters} = (1000+1) * 256 + (256+1) * 1000 = 256256 + 257000 = 513256$$
  
$$\text{Output\_size} = (256)$$
- لایه‌های دهم RNN ها هستند. در هر کدام از آنها داریم:  
$$\# \text{ of parameters} = \# \text{ of FFNN} * (\# \text{ of hidden neurons} + \text{input\_size}) + \# \text{ of hidden neurons}$$
$$= 1 * (128 * (128+256)+128) = 49280$$
$$\text{Output\_size} = (128)$$

- لایه یازدهم کاملاً متصل است که به RNN ها متصل هستند.

# of parameters =  $(128 + 1) * 128 = 16512$

Output\_size = (128)

- لایه دوازدهم concatenate است که خروجی دو لایه Dense قبلی را با هم ترکیب می کند. در نتیجه (256) سائز خروجی میشود. پارامتر هم ندارد.

- لایه سیزدهم مجدد کاملاً متصل است.

# of parameters =  $(256 + 1) * 128 = 32896$

Output\_size = (128)

ورودی لایه قبلی که (256) است را به تعداد unit که (128) تبدیل می کند.

- لایه چهاردهم که آخرین لایه نیز هست هم کاملاً متصل است. پس داریم:

# of parameters =  $(128 + 1) * 1000 = 129000$

Output\_size = (1000)

خروجی با توجه به embedding کلمات این سائز می شود.

لینک های کمکی)

<https://machinelearningmastery.com/use-word-embedding-layers-deep-learning-keras/>

<https://medium.com/analytics-vidhya/understanding-embedding-layer-in-keras-bbe3ff1327ce>

<https://towardsdatascience.com/a-guide-to-word-embeddings-8a23817ab60f>

<https://towardsdatascience.com/counting-no-of-parameters-in-deep-learning-models-by-hand-8f1716241889#192e>

session\_15 and session\_13 and session\_20 slides of course

## سوال دوم)

شرح کد:

در این کد ابتدا مجموعه داده reuters را از سایت nltk دانلود و بر روی drive خود آپلود می کنیم. سپس با استفاده از تابع fields داده های با category خام یا crudes را جدا می کنیم و ۱۰۰ تا عضو اول آن را در حلقه جدا می کنیم. با استفاده از کد موجود در داک تمرین کلمات را در هر نمونه به هم چسبانیدیم تا جملات ساخته شود و آن ها را در لیست sentences ذخیره کردم.

حال برای ساخت شبکه برای آموزش word\_embedding با طول ۲ طبق لینک داده شده داریم:

ابتدا لایه ورودی قرار دارد که ۲۸۲۳ نورون دارد. سپس لایه کاملاً متصل قرار دارد که فعالساز آن linear است. در آخر یک لایه متصل دیگر با فعالساز softmax قرار دارد.

## الف)

در این سوال پیش پردازش های مختلفی توسط تابع text\_preprocessing انجام شده است. این موارد به ترتیب در زیر آمده است:

ابتدا در حلقه اولیه punctuation ها با رشته خالی جایگزین شده اند. سپس کلماتی که در آنها رقم وجود داشته باشد، حذف شده اند. سپس ارقام حذف شدند. در مرحله بعد تعداد اسپیس های خالی اضافی بهینه شدند. بعد تمامی کلمات به صورت lower در آمدند. در نهایت همه کلمات text در یک لیست ذخیره شده و stop\_word ها از میان آنها حذف شدند.

Stop\_word ها در واقع کلماتی هستند که به خودی خود معنا ندارند و در جمله معنی خواهند داد. کار آنها جداسازی و اتصال جملات است. به همین دلیل این نام را دارند.

سپس به اندازه پنجره، فاصله ای به همان میزان از کلمات جدا و آن ها را در لیست های جدا ذخیره می کند. در آخر با استفاده از تابع create\_unique\_word\_dict موارد تکراری را حذف می کند.

## ب)

کلمات هر خبر را با توجه به اندازه ی پنجره، دوتا دوتا در یک آرایه از کلمات دوتایی که word\_lists نام دارد، قرار می دهیم. سپس مجموعه هایی که دو بار تکرار دارند را از این لیست به کمک تابع creat\_unique\_word\_dict حذف می کند تا کلمات یکتا باشند و یک دیکشنری از کلمات می سازد.

سپس یک ماتریس با ابعاد num\_words\*num\_words در نظر می گیریم و برای هر لیست از کلمات، در مختصات x کلمه ی اول و y کلمه ی دوم عدد ۱ را می گذارد تا نشان دهنده ی آن باشد که این دو کلمه با هم در ارتباط هستند. سپس بردار x ها را به عنوان ورودی شبکه و بردار y ها را به عنوان خروجی مورد انتظار در نظر می گیریم و دو x ها و y ها را از هم جدا می کنیم. چون با اینکار، یک ماتریس بسیار بزرگ به وجود می آید که بسیاری از عناصر آن ۰ هستند، به کمک تابع sparse.csr\_matrix ماتریس را متراکم می کند. در واقع ۲۸۲۳ نورون را با ۵۴۵۵۶ داده ورودی می دهیم.

(ج)


با افزایش ساین پنجره، تعداد امکان مقایسه برای هر کلمه بیشتر خواهد شد و تعداد زوج داده ما نیز بیشتر خواهند شد. در نتیجه ارتباط کلمات دقیق تر و با جزئیات بهتر آموزش دیده می شود. اما زمان ران شدن شبکه نیز طولانی تر خواهد شد. ساین کمتر نیز دقیقاً بالعکس حالت قبل است. به این معنی که دقت و آموزش ضعیف تر خواهد بود.

(د

به هریک از 2823 نوروں ورودی دو نوروں میانی متصل است. پس برای هر ورودی ما دو وزن خواهیم داشت. ورن نخست مربوط به  $x$  و وزن دوم مربوط به  $y$  خواهد بود.

### تحلیل شبکه:

پس از آموزش شبکه، شکب روابط کلمات در دیتاست به صورت زیر در می آید:




نتایج نهایی شبکه پس از epoch ۱۰۰۰ نیز به صورت مقابل است:

```
Epoch 1000/1000  
52920/52920 [=====] - 6s 111us/step - loss:  
6.2440
```

در اینجا همچنان میزان خطا بالاست و تا بهینگی فاصله هست اما یک سری دسته بندی ها نیز شکل گرفته است.


سپس کلمات خواسته شده را در یک لیست ذخیره و به شبکه می دهیم. Iran و Iraq به طور مثال به عنوان کشور تشخیص داده شده اند و در کنار هم هستند ولی مثلا Kuwait هنوز خطا دارد.

کلمات economy و energy و oil و gas و nuclear نیز در دسته انرژی و سوخت تشخیص داده شده و کنار هم آمده اند.



برای قسمت آخر مجبور شدم شبکه را دوباره ران کنم چون که ران تایم ریست شده بود. و اینبار با تعداد کمر ران کردم تا خروجی این قسمت هم نمایش دهم.

کلمات Germany و large, big, massive, turkey, petrol را اضافه کردم و نتیجه به صورت زیر در آمد:



کلمات big و large و massive تقریباً در نزدیکی هم قرار گرفتند و Germany و turkey نیز به سایر کشورها نزدیک هستند.

لینک های کمکی:

[Python Examples of nltk.corpus.reuters.fileids \(programcreek.com\)](http://pythonexamples.org/nltk.corpus.reuters.fileids/)

<https://machinelearningmastery.com/what-are-word-embeddings/>

Session\_21 slide of course

## سوال سوم)

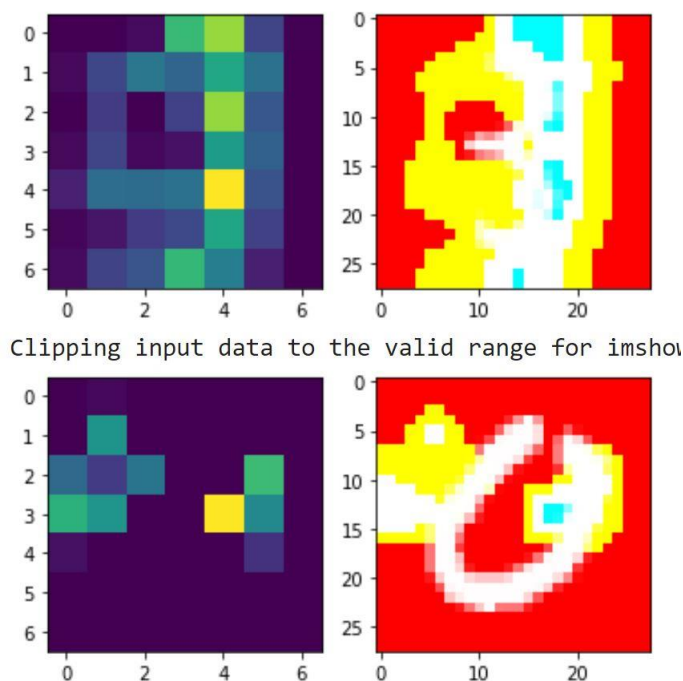
در این تمرین مشابه تمرین سری ششم، ابتدا مجموع داده MNIST که شامل 60K داده آموزشی و 10K داده تست است، را اضافه می کنیم. سپس دیتا را به هم میریزیم و با تابع `reshape` یک بعد به آن اضافه می کنیم تا بتوان عکس های این دیتاست را به عنوان ورودی لایه `conv` استفاده کنیم. سپس داده های را نرمالایز کرده و آن ها را به شکل `one hot` در می آوریم.

سپس شبکه را با مقادیر خواسته شده تشکیل می دهیم و در پانزده `epoch` و با `batch_size` 64 تایی آموزش می دهیم.


در آخر در قسمت `grad_cam` نیز نام آخرین لایه کانولوشن را از قسمت `summary` بدست می آوریم و از آن لایه را توسط تابع `get_layer` بدست می آوریم. سپس تعدادی از `index` های داده های آموزشی را جدا کرده و سپس عملیات نمایش `heat map` را آغاز می کنیم. در این بخش ابتدا برای بدست آوردن کلاس خروجی هر تصویر مورد نظر ابتدا تابع `predict` را روی هر کدام فراخوانی می کنیم.

سپس یک آرایه از ایندکس کلاس های خروجی هر عکس تشکیل می دهیم. در نهایت طبق مراحل الگوریتم اسلاید پیش می رویم و مراحل محاسبه گرادیان و محاسبه خروجی لایه گرادیان را انجام می دهیم. در نهایت از خروجی لایه `conv` هیت مپ را تشکیل می دهیم و سپس عکس اصلی را با تاثیر هیپ مپ روی هم انداخته و نمایش می دهیم.



خروجی های این سوال را در قسمت زیر مشاهده می کنید:









Clipping input data to the valid range for imshow



Clipping input data to the valid range for imshow





تحلیل خروجی ها: همانطور که مشاهده می کنید، در خروجی های سمت چپ هیپ مپ مربوط به هر عکس ورودی مشخص شده است که در واقع خروجی لایه conv است. سپس در خروجی های قسمت راست تاثیر این هیت مپ را روی عکس اصلی مشاهده می کنید.

برای تعدادی از این عکس های شبکه نتوانسته تشخیص خوبی را داشته باشد. به طور مثال عکس ۹ و ۰ را خوب تشخیص نداده اما ۳ و ۵ رو نماد های خوبی برای تشخیص و جداسازی آن ها پیدا کرده است.

لینک های کمکی:

<https://www.machinecurve.com/index.php/2019/11/28/visualizing-keras-cnn-attention-grad-cam-class-activation-maps/>

[https://keras.io/examples/vision/grad\\_cam/](https://keras.io/examples/vision/grad_cam/)

<https://github.com/jacobgil/keras-cam/blob/master/cam.py>

<https://stackoverflow.com/questions/66221788/tf-gradients-is-not-supported-when-eager-execution-is-enabled-use-tf-gradientta>

session\_20 slide of course